

Klasifikasi Otomatis Laporan Masyarakat pada Platform LAPOR! Melalui Pendekatan Arsitektur Model Vector Embeddings

Brian Juniarta Darmadi

Computer Science Department,
School of Computer Science Bina
Nusantara University
Jakarta, Indonesia
brian.darmadi@binus.ac.id

Mirekel Tjoa

Computer Science Department,
School of Computer Science Bina
Nusantara University
Jakarta, Indonesia
mirekel.tjoa@binus.ac.id

Mochammad Aqsa Sandhy Pradipta
Computer Science Department,
School of Computer Science Bina
Nusantara University
Jakarta, Indonesia
mochammad.pradipta@binus.ac.id

Intisari — Sistem Pengelolaan Pengaduan Pelayanan Publik Nasional (SP4N-LAPOR!) merupakan kanal vital bagi partisipasi masyarakat, namun menghadapi tantangan besar dalam efisiensi akibat volume laporan yang tinggi. Proses klasifikasi laporan ke instansi berwenang yang masih dilakukan secara manual terbukti lambat dan rentan terhadap kesalahan, sehingga berpotensi menurunkan kualitas layanan dan kepercayaan publik. Penelitian ini bertujuan untuk merancang dan mengevaluasi sebuah model deep learning untuk mengotomatisasi proses klasifikasi laporan pada platform LAPOR!. Metodologi yang diusulkan menggunakan arsitektur hybrid yang mengintegrasikan model pre-trained IndoBERT sebagai ekstraktor fitur untuk menghasilkan contextual embedding dari teks laporan, yang kemudian diolah oleh lapisan klasifier berbasis Bidirectional Gated Recurrent Unit (Bi-GRU). Model dievaluasi menggunakan dataset berisi 5.000 laporan publik dengan 19 kategori berbeda. Hasil eksperimen menunjukkan bahwa arsitektur hybrid IndoBERT + Bi-GRU yang diusulkan berhasil mencapai performa yang unggul dengan akurasi 93,85% dan F1-Score sebesar 93,73%. Kinerja ini melampaui arsitektur pembanding lainnya, termasuk penggunaan IndoBERT sebagai klasifier end-to-end maupun kombinasi dengan Bi-LSTM. Tingkat akurasi yang tinggi ini menunjukkan bahwa model yang diusulkan merupakan solusi yang sangat layak dan efektif untuk mengotomatisasi kategorisasi pengaduan, sehingga dapat mempercepat proses disposisi laporan dan mendukung terwujudnya institusi publik yang lebih akuntabel dan responsif.

Kata Kunci — Klasifikasi Teks, Pengaduan Publik, LAPOR!, IndoBERT, Bi-GRU, Deep Learning

I. INTRODUCTION

A. Latar Belakang

Partisipasi masyarakat merupakan salah satu pilar utama dalam penyelenggaraan pemerintahan yang baik dan transparan. Di era digital, pemanfaatan teknologi informasi dan komunikasi menjadi jembatan esensial antara pemerintah dan masyarakat. Indonesia telah mengadopsi sistem e-government melalui Sistem Pengelolaan Pengaduan Pelayanan Publik Nasional (SP4N) – Layanan Aspirasi dan Pengaduan Online Rakyat (LAPOR!), yang menjadi kanal utama bagi masyarakat untuk menyampaikan aspirasi dan pengaduan terkait pelayanan publik. Sistem ini dirancang untuk memastikan setiap laporan dapat tersalurkan kepada instansi yang berwenang secara cepat dan akuntabel [1]. Inisiatif penguatan kelembagaan pelayanan publik ini sejalan dengan komitmen global dalam Tujuan Pembangunan Berkelanjutan (SDGs), khususnya Tujuan ke-16 yakni

"Perdamaian, Keadilan, dan Kelembagaan yang Tangguh". Lebih lanjut, upaya ini merupakan perwujudan langsung dari salah satu pilar Asta Cita, yaitu meningkatkan pelayanan publik yang efisien, efektif, dan berbasis digital untuk menyempurnakan reformasi birokrasi.

Akan tetapi, efektivitas SP4N-LAPOR! kini berada di bawah tekanan besar akibat lonjakan volume laporan harian. Tingginya volume ini membebani proses verifikasi dan klasifikasi yang masih dilakukan secara manual, sehingga memunculkan sebuah hambatan fundamental: keharusan bagi pengguna untuk memilih kategori pengaduan secara mandiri. Proses ini terbukti tidak efisien dan rentan terhadap kesalahan (human error), yang mengakibatkan laporan seringkali salah alamat ke instansi yang tidak berwenang. Kesalahan klasifikasi ini secara langsung menyebabkan penundaan signifikan karena laporan harus diverifikasi ulang dan dialihkan, sehingga mencederai janji sistem akan kecepatan dan akuntabilitas [2]. Berbagai studi yang mengkaji efektivitas LAPOR! secara konsisten menunjukkan bahwa kelambatan dalam penyaluran laporan ini merupakan faktor krusial yang tidak hanya menurunkan tingkat kepuasan, tetapi juga berpotensi mengikis kepercayaan masyarakat terhadap kualitas pelayanan publik [3].

Untuk mengatasi permasalahan ini, berbagai penelitian telah mengeksplorasi pemanfaatan text mining dan Natural Language Processing (NLP) untuk mengklasifikasikan teks pengaduan secara otomatis. Penelitian terdahulu telah menerapkan berbagai metode, mulai dari algoritma machine learning klasik seperti Naïve Bayes [4] hingga model deep learning yang lebih kompleks seperti Recurrent Neural Network (RNN) untuk mengolah data teks dari situs LAPOR! [5]. Perkembangan terkini bahkan menunjukkan penggunaan model berbasis Transformer seperti IndoBERT yang mampu mencapai tingkat akurasi tinggi dalam memahami konteks bahasa Indonesia untuk klasifikasi pengaduan [6]. Adopsi teknologi ini menjanjikan sebuah solusi untuk mengotomatisasi proses kategorisasi, sehingga dapat meminimalisir keterlambatan dan meningkatkan akurasi penyaluran laporan. Projek ini akan berfokus pada pengembangan model prediktif untuk otomatisasi klasifikasi kategori laporan di platform "SP4N-LAPOR!".

B. Tujuan

Berdasarkan latar belakang yang telah diuraikan, penelitian ini bertujuan untuk mengatasi masalah kelambatan dan ketidakefisienan dalam proses penyelesaian pengaduan di

platform "PS4N-LAPOR!", yaitu melalui klasifikasi otomatis sehingga dapat meningkatkan akurasi dan mempercepat proses disposisi laporan dengan memastikan setiap pengaduan dapat secara otomatis tersalurkan ke instansi pemerintah yang berwenang. Dengan demikian proses manual yang rentan terhadap kesalahan (human error) dapat diminimalisir, dan waktu tunggu dari laporan masuk hingga ditangani oleh pihak yang tepat dapat dipersingkat secara signifikan. Untuk mencapai tujuan utama tersebut, maka dirumuskan beberapa sasaran teknis sebagai berikut:

1. Merancang dan membangun sebuah model machine learning yang efektif dalam mengklasifikasikan kategori laporan secara otomatis berdasarkan data teks dari situs lapor.go.id.
2. Mengevaluasi performa model yang diusulkan menggunakan matrik evaluasi yang relevan, untuk memastikan model tersebut layak dan mampu menggantikan proses klasifikasi manual yang ada saat ini.

C. Manfaat

Implementasi dari model yang diusulkan diharapkan dapat memberikan manfaat yang signifikan dan berlapis. Bagi pemerintah selaku pengelola layanan, manfaat utamanya adalah peningkatan drastis dalam efisiensi dan kecepatan proses disposisi laporan. Otomatisasi klasifikasi dapat memangkas waktu verifikasi awal, memastikan laporan sejak awal tersalurkan ke instansi yang berwenang, dan mengurangi potensi kesalahan manusia yang dapat menghambat alur kerja. Namun, dampak yang lebih strategis adalah optimalisasi alokasi sumber daya manusia. Dengan membebaskan petugas dari tugas klasifikasi yang repetitif, mereka dapat lebih fokus pada tugas-tugas kompleks seperti analisis masalah, koordinasi penyelesaian, dan penanganan kasus-kasus prioritas. Lebih jauh lagi, model ini akan menghasilkan data laporan yang terstruktur dan akurat secara konsisten, yang dapat menjadi pondasi untuk pengambilan kebijakan berbasis data (data-driven policymaking). Pemerintah dapat mengidentifikasi pola pengaduan, area dengan masalah kronis, serta kinerja antar-instansi secara objektif untuk melakukan intervensi yang lebih tepat sasaran.

Berbagai peningkatan di sisi pemerintah ini kemudian akan memberikan dampak langsung bagi masyarakat. Selain kemudahan proses pelaporan tanpa perlu bingung memilih kategori, manfaat yang paling dirasakan adalah percepatan resolusi masalah. Pengaduan mengenai infrastruktur rusak, layanan administrasi yang lambat, atau isu sosial lainnya dapat ditangani lebih cepat, yang secara langsung meningkatkan kualitas hidup warga. Pada akhirnya, sebuah sistem pengaduan yang responsif, akuntabel, dan efektif merupakan instrumen fundamental untuk membangun dan menjaga kepercayaan publik terhadap pemerintah dan institusi pelayanannya. Dengan demikian, otomatisasi klasifikasi laporan ini bukan sekadar inovasi teknis, melainkan sebuah langkah strategis untuk mengakselerasi pencapaian agenda Asta Cita dalam menciptakan birokrasi digital yang melayani, sekaligus berkontribusi nyata pada realisasi target SDG 16 untuk membangun institusi yang efektif, akuntabel, dan inklusif di semua tingkatan.

D. Batasan Masalah

Studi ini memiliki beberapa keterbatasan dalam pendekatan yang digunakan, yaitu:

1. Sumber data yang digunakan terbatas pada jumlah data dan feature yang diambil dari situs lapor.go.id, yaitu sebanyak 5000 baris yang berisi judul, deskripsi, dan kategori laporan.
2. Fokus proyek ini berada pada pengembangan model klasifikasi berbasis teks. Fitur lain di luar teks laporan, seperti data gambar atau lokasi, tidak akan digunakan dalam pemodelan.
3. Lingkup implementasi proyek ini mencakup perancangan, pelatihan, dan evaluasi model. Tahap implementasi atau deployment model ke dalam sistem lapor.go.id secara real-time tidak termasuk dalam cakupan proyek ini.

II. STUDI LITERATURE

A. Klasifikasi Teks pada Pengaduan Publik

Pengelolaan pengaduan masyarakat merupakan elemen krusial dalam ekosistem e-government untuk menjaga kualitas layanan dan kepercayaan publik. Platform seperti SP4N-LAPOR! di Indonesia menjadi kanal utama bagi masyarakat, namun menghadapi tantangan besar akibat volume laporan yang terus meningkat. Berbagai studi telah menyoroti bahwa efektivitas platform ini sangat bergantung pada kecepatan dan ketepatan proses verifikasi serta disposisi laporan ke instansi yang berwenang [1], [2]. Proses manual yang ada saat ini terbukti menjadi penghambat, menyebabkan penundaan dan potensi kesalahan klasifikasi. Kondisi ini mendorong kebutuhan mendesak untuk otomatisasi. Oleh karena itu, klasifikasi teks otomatis menjadi solusi yang banyak dieksplorasi oleh para peneliti untuk meningkatkan efisiensi dan akuntabilitas sistem pengaduan publik [3].

B. Representasi Teks dengan Contextual Embeddings

Langkah fundamental dalam klasifikasi teks adalah mengubah teks menjadi representasi vektor numerik yang dapat diproses oleh model machine learning. Pendekatan awal menggunakan metode statistik seperti Term Frequency-Inverse Document Frequency (TF-IDF), yang merepresentasikan teks berdasarkan frekuensi kemunculan kata, namun gagal menangkap hubungan semantik antar kata [4]. Evolusi selanjutnya adalah static word embedding seperti Word2Vec, yang mampu memetakan kata ke dalam vektor dan menangkap hubungan semantik (misalnya, vektor "raja" - "pria" + "wanita" mendekati vektor "ratu"), namun memiliki keterbatasan karena satu kata hanya memiliki satu representasi vektor tanpa memperhitungkan konteks kalimatnya [5].

Terobosan signifikan hadir melalui arsitektur Transformer yang memperkenalkan mekanisme self-attention, memungkinkan model untuk memahami konteks sebuah kata dengan menimbang relevansinya terhadap semua kata lain dalam sebuah kalimat [6]. Berdasarkan arsitektur ini, model seperti BERT (Bidirectional Encoder Representations from Transformers) dikembangkan dan dilatih pada data dalam skala masif untuk menghasilkan contextual embeddings [7]. Dalam metodologi penelitian ini, model turunan BERT yang spesifik untuk Bahasa Indonesia, yaitu IndoBERT [8], tidak digunakan sebagai klasifier end-to-end, melainkan sebagai ekstraktor fitur yang canggih. IndoBERT bertugas untuk

menghasilkan representasi vektor yang kaya akan informasi kontekstual dari setiap laporan pengaduan, yang kemudian menjadi input untuk model klasifier.

C. Model Klasifikasi Berbasis Recurrent Neural Network

Setelah teks direpresentasikan menjadi vektor embedding yang berkualitas, langkah selanjutnya adalah memasukkannya ke dalam sebuah model classifier untuk menentukan kategori akhir. Keluarga Recurrent Neural Network (RNN) merupakan arsitektur yang secara inheren cocok untuk memproses data sekuensial, termasuk sekuens dari vektor kata. Penelitian oleh Rozi, dkk. [9] menunjukkan penerapan arsitektur RNN untuk klasifikasi laporan di situs LAPOR!, membuktikan kelayakan pendekatan ini.

Namun, RNN standar memiliki kelemahan dalam menangani dependensi jangka panjang atau vanishing gradient problem. Untuk mengatasinya, dikembangkan varian yang lebih canggih seperti Long Short-Term Memory (LSTM), yang memiliki "sel memori" dan tiga "gerbang" (gates) untuk mengatur aliran informasi, memungkinkannya "mengingat" informasi penting dari bagian teks yang jauh [10]. Varian lain yang lebih modern dan efisien secara komputasi adalah Gated Recurrent Unit (GRU). GRU menyederhanakan arsitektur LSTM dengan hanya menggunakan dua gerbang, sehingga mengurangi jumlah parameter dan seringkali mempercepat proses pelatihan tanpa mengorbankan performa secara signifikan [11]. Dalam penelitian ini, arsitektur LSTM dan GRU digunakan sebagai lapisan klasifier yang akan memproses hasil embedding dari IndoBERT untuk menghasilkan prediksi kategori laporan.

III. METODOLOGI

A. Dataset

TABLE I. Tabel Isi Dataset

Complaint Title	Complaint Description	Main Category
Jalan Macan Putih Labanasem Bolong Dan Sangat ...	Kepada yth dinas pekerjaan umum cipta karya pekerjaan umum...	PEKERJAAN UMUM DAN PENATAAN RUANG
Jalan Dsn Sukopuro Rusak	Kepada yth dinas pekerjaan umum cipta karya pekerjaan umum...	PEKERJAAN UMUM DAN PENATAAN RUANG
Jadwal Kapal	Sebelumnya saya pernah melihat jadwal kapal di...	PERHUBUNGAN
Jalan Rusak	Gus saya erie koebianto dari ds banjar agung...	PEKERJAAN UMUM DAN PENATAAN RUANG
Kur Umkm	Siang pak saya anak dari alm suhardi batubara,...	EKONOMI DAN KEUANGAN

Dataset yang digunakan dalam penelitian ini diperoleh dari situs resmi SP4N-LAPOR! (lapor.go.id). Dataset ini mencakup 5000 entri laporan publik, yang masing-masing terdiri dari tiga atribut utama, yaitu judul laporan, deskripsi

laporan, dan kategori laporan. Setiap entri merepresentasikan satu laporan masyarakat yang telah dikategorikan secara manual ke dalam salah satu dari beberapa kategori yang tersedia.

TABLE II. Pembagian Kategori Laporan

Kategori Utama	Jumlah
TOPIK LAINNYA	746
PEKERJAAN UMUM DAN PENATAAN RUANG	546
KETENAGAKERJAAN	262
SOSIAL DAN KESEJAHTERAAN	212
PENDIDIKAN DAN KEBUDAYAAN	203
KETENTERAMAN, KETERTIBAN UMUM, DAN PELINDUNG MASYARAKAT	194
PERHUBUNGAN	175
LINGKUNGAN HIDUP DAN KEHUTANAN	161
TEKNOLOGI INFORMASI DAN KOMUNIKASI	154
KESEHATAN	98
EKONOMI DAN KEUANGAN	93
KEPENDUDUKAN	93
ENERGI DAN SUMBER DAYA ALAM	77
POLITIK DAN HUKUM	47
SP4N-LAPOR!	44
CORONA VIRUS	38
PERLINDUNGAN KONSUMEN	28
AGAMA	20
PEMBANGUNAN DESA, DAERAH TERTINGGAL, DAN TRANSMIGRASI	19
PERTANIAN DAN PETERNAKAN	19
PEMULIHAN EKONOMI NASIONAL	15

Setelah dilakukan analisis awal terhadap distribusi kategori, ditemukan adanya ketidakseimbangan kelas (class imbalance) yang cukup signifikan. Beberapa kategori mendominasi jumlah entri, sementara sebagian kategori lainnya memiliki sangat sedikit data per kelas. Oleh karena itu, untuk menangani masalah ketidakseimbangan ini, penelitian ini tidak menggunakan teknik oversampling ataupun undersampling. Sebagai gantinya, pendekatan class weighting diterapkan dalam proses pelatihan model. Dengan demikian, model dapat memberikan bobot lebih besar pada kelas minoritas sehingga performa klasifikasi menjadi lebih adil dan seimbang.

B. Alur Eksperimen

Alur eksperimen dalam penelitian ini dimulai dengan proses pra-pemrosesan data yang mencakup pembersihan teks dan penggabungan kolom judul dan deskripsi laporan menjadi satu teks utuh. Selanjutnya, representasi teks diubah menjadi vektor numerik menggunakan berbagai teknik embedding terkini. Embedding yang digunakan mencakup Multilingual

E5, Qwen3, FastText, IndoBERT, dan CendolT5. Setelah proses embedding, hasil vektorisasi teks digunakan sebagai input untuk pelatihan model klasifikasi berbasis neural network. Dataset dibagi menjadi dua bagian dengan rasio 70:30 secara stratifikasi terhadap label kategori, di mana 80% digunakan sebagai data latih dan 30% sebagai data uji.

C. Model

Model klasifikasi yang digunakan dalam penelitian ini adalah Long Short-Term Memory (LSTM), yang dirancang khusus untuk menangani data sekuensial seperti teks. Arsitektur model terdiri atas satu lapisan LSTM dengan 128 unit memori, diikuti oleh satu dense layer dengan 64 neuron dan fungsi aktivasi ReLU, serta output layer dengan aktivasi softmax untuk klasifikasi multi-kelas. Model dilatih selama 50 epoch dengan ukuran batch sebesar 32 menggunakan optimizer Adam. Untuk mengatasi permasalahan ketidakseimbangan kelas (class imbalance), digunakan fungsi loss categorical cross-entropy yang dibobot berdasarkan distribusi label pada data latih. Pembobotan kelas ini memungkinkan model untuk memperhatikan kelas minoritas tanpa melakukan oversampling atau duplikasi data.

IV. HASIL DAN PEMBAHASAN

Evaluasi kinerja model dilakukan dengan menggunakan tiga metrik utama, yaitu akurasi (accuracy), F1-score makro (F1-macro), dan Area Under the Curve (AUC). F1-macro dipilih sebagai metrik utama dalam penelitian ini karena mempertimbangkan performa model secara seimbang terhadap seluruh kelas, terlepas dari distribusi data.

TABLE III. Tabel Pelatihan Model

Embedding	Accuracy	F1	AUC
Multilingual-E5	0.7177	0.5048	0.9367
Qwen3	0.6899	0.5249	0.9317
FastText	0.6530	0.4804	0.9320
IndoBERT	0.6016	0.4440	0.9006
CendolT5	0.5739	0.3860	0.8916

Hasil pengujian terhadap kelima metode embedding menunjukkan variasi performa yang signifikan. Model dengan embedding Multilingual-E5 menghasilkan akurasi tertinggi sebesar 0.7177 dan nilai AUC tertinggi sebesar 0.9367. Di sisi lain, embedding Qwen3 mencatatkan nilai F1-macro tertinggi yaitu 0.5249, meskipun akurasinya sedikit lebih rendah dibandingkan Multilingual-E5. FastText memberikan hasil menengah dengan F1-macro sebesar 0.4804 dan AUC sebesar 0.9320. Sementara itu, model berbasis IndoBERT dan CendolT5 menunjukkan performa yang lebih rendah baik dari segi akurasi, F1-macro, maupun AUC.

Performa yang lebih baik pada embedding Multilingual-E5 dan Qwen3 dapat dikaitkan dengan kemampuan representasional yang lebih kuat dalam menangkap konteks lintas bahasa dan pemahaman semantik kalimat. Sementara embedding seperti IndoBERT dan CendolT5 yang secara eksplisit dilatih pada Bahasa Indonesia ternyata tidak memberikan hasil yang lebih baik. Hal ini kemungkinan disebabkan oleh keterbatasan domain data pre-training yang kurang sesuai dengan karakteristik data SP4N-LAPOR! atau

karena kapasitas representasinya yang lebih sempit pada level kalimat

REFERENCES

The template will number citations consecutively within brackets [1]. The sentence punctuation follows the bracket [2]. Refer simply to the reference number, as in [3]—do not use “Ref. [3]” or “reference [3]” except at the beginning of a sentence: “Reference [3] was the first ...”

Number footnotes separately in superscripts. Place the actual footnote at the bottom of the column in which it was cited. Do not put footnotes in the abstract or reference list. Use letters for table footnotes.

Unless there are six authors or more give all authors' names; do not use “et al.”. Papers that have not been published, even if they have been submitted for publication, should be cited as “unpublished” [4]. Papers that have been accepted for publication should be cited as “in press” [5]. Capitalize only the first word in a paper title, except for proper nouns and element symbols.

For papers published in translation journals, please give the English citation first, followed by the original foreign-language citation [6].

- [1] G. Eason, B. Noble, and I. N. Sneddon, “On certain integrals of Lipschitz-Hankel type involving products of Bessel functions,” Phil. Trans. Roy. Soc. London, vol. A247, pp. 529–551, April 1955. (references)
- [2] J. Clerk Maxwell, A Treatise on Electricity and Magnetism, 3rd ed., vol. 2. Oxford: Clarendon, 1892, pp.68–73.
- [3] I. S. Jacobs and C. P. Bean, “Fine particles, thin films and exchange anisotropy,” in Magnetism, vol. III, G. T. Rado and H. Suhl, Eds. New York: Academic, 1963, pp. 271–350.
- [4] K. Elissa, “Title of paper if known,” unpublished.
- [5] R. Nicole, “Title of paper with only first word capitalized,” J. Name Stand. Abbrev., in press.
- [6] Y. Yorozu, M. Hirano, K. Oka, and Y. Tagawa, “Electron spectroscopy studies on magneto-optical media and plastic substrate interface,” IEEE Transl. J. Magn. Japan, vol. 2, pp. 740–741, August 1987 [Digests 9th Annual Conf. Magnetics Japan, p. 301, 1982].
- [7] M. Young, The Technical Writer’s Handbook. Mill Valley, CA: University Science, 1989.
- [8] K. Eves and J. Valasek, “Adaptive control for singularly perturbed systems examples,” Code Ocean, Aug. 2023. [Online]. Available: <https://codeocean.com/capsule/4989235/tree>
- [9] D. P. Kingma and M. Welling, “Auto-encoding variational Bayes,” 2013, arXiv:1312.6114. [Online]. Available: <https://arxiv.org/abs/1312.6114>
- [10] S. Liu, “Wi-Fi Energy Detection Testbed (12MTC),” 2023, GitHub repository. [Online]. Available: <https://github.com/liustone99/Wi-Fi-Energy-Detection-Testbed-12MTC>
- [11] “Treatment episode data set: discharges (TEDS-D): concatenated, 2006 to 2009.” U.S. Department of Health and Human Services, Substance Abuse and Mental Health Services Administration, Office of Applied Studies, August, 2013, DOI:10.3886/ICPSR30122.v2

IEEE conference templates contain guidance text for composing and formatting conference papers. Please ensure that all template text is removed from your conference paper prior to submission to the conference. Failure to remove template text from your paper may result in your paper not being published.

We suggest that you use a text box to insert a graphic (which is ideally a 300 dpi TIFF or EPS file, with all fonts embedded) because, in an MSW document, this method is somewhat more stable than directly inserting a picture.

To have non-visible rules on your frame, use the MSWord “Format” pull-down menu, select Text Box > Colors and Lines to choose No Fill and No Line.